

RAPPRESENTAZIONE DIGITALE DELLE INFORMAZIONI

Informazione oggi

- *Informatica*: disciplina che studia l'elaborazione automatica di informazioni.
- *Elaboratore*: sistema per l'elaborazione automatica delle informazioni.
- *Programmabilità*: un elaboratore e' programmabile se e' in grado di svolgere compiti diversi in base ad un programma
- *Codifica*: Ogni informazione può (a meno di un'approssimazione) essere rappresentata come una sequenza di due soli simboli (Es: 0 e 1)

Automazione

- Per *automatico* si intende tutto ciò che compie un compito prestabilito senza l'intervento umano.
- Un qualche processo viene automatizzato quando il numero di volte che esso deve essere eseguito è sufficientemente grande da rendere conveniente la progettazione e la costruzione di un sistema automatico che lo risolva.

Alcuni esempi

Problema originale (non ripetitivo)	Problema sistematico e ripetitivo
<i>Soluzione manuale</i>	<i>Soluzione automatica</i>
Determinare il diametro di una pallina	Classificare un insieme di palline in base al diametro
<i>Calibro</i>	<i>Griglie forate</i>
Scrivere una lettera	Riprodurre un testo in migliaia di copie
<i>Carta e penna</i>	<i>Stampa tipografica</i>
Regolare il traffico in caso di emergenza	Regolare il traffico ad ogni incrocio
<i>Vigile urbano</i>	<i>Semaforo</i>
Riempire un contenitore d'acqua	Riempire ripetutamente un contenitore con la stessa quantità d'acqua
<i>Rubinetto manuale</i>	<i>Rubinetto a galleggiante</i>

BIT (Binary Digit)

- Letteralmente la parola bit significa cifra binaria
- In generale un bit e' una unita' che puo' assumere un valore tra due possibili (normalmente si parla di 0 e 1)
- La rappresentazione fisica di un bit richiede un qualsiasi dispositivo in grado di trovarsi in uno di due possibili stati
- Interruttore (accesso/spento)
- Un condensatore (carico/scarico)
- Una bandiera (alzata/abbassata)
- Una particella magnetica (Nord/Sud)

Codifica

- La codifica e' un'operazione che consente di utilizzare i calcolatori elettronici per elaborare dati di qualsiasi natura.
- Un bit puo' assumere solo due valori (0 e 1)
- Per rappresentare insiemi costituiti da piu' di due stati/simboli si usano stringhe di bit
- Una stringa di bit e' costituita da un numero n di bit ed e' comunemente detta parola (*word*)
- Con n bit si possono formare 2^n configurazioni diverse e quindi si possono rappresentare 2^n informazioni diverse

Codifica del testo

- Un testo e' una sequenza di caratteri alfabetici, separatori e caratteri speciali
- Ad ogni carattere e' associata una diversa configurazione di bit.
- Esempio: 21 lettere dell'alfabeto + 10 numeri + 10 punteggiatura = 41 simboli
 - $2^5 = 32$ combinazioni
 - $2^6 = 64$ combinazioni \rightarrow ok

Possiamo usare una codifica a 6 bit.

Esempio codifica testo a 6 bit

- 000000 = a
- 000001 = b
- 000010 = c
- 000011 = d
- 000100 = e
- 000101 = f
- 000110 = g
- 000111 = h

Un testo è rappresentato dalla sequenza di byte associati ai caratteri che lo compongono, nell'ordine in cui essi compaiono

Standard ASCII

(American Standard Code for Information Interchange)

- La codifica ASCII prevede l'utilizzo di 128 caratteri diversi
- Ogni carattere e' associato ad una diversa configurazione di 7 bit
- La codifica ASCII estesa prevede 256 simboli e 8 bit (*1byte*) per ogni carattere
- Quindi un testo di 1000 caratteri richiede 1Kbyte per essere rappresentato

Standard Unicode

- Lo standard ISO10646/Unicode si basa su una codifica a 32 bit che consente oltre due miliardi di possibili caratteri
- UTF usa 7 bit per carattere per codificare i primi 127 caratteri corrispondenti all'ASCII standard, e attiva l'ottavo bit solo quando serve la codifica Unicode.

Codifica

- Una codifica esatta a n bit è possibile solo quando l'insieme delle informazioni da codificare è finito e di dimensione inferiore a 2^n (*cardinalità*).
- I calcolatori sono oggetti finiti che elaborano e memorizzano un numero finito di bit
- Se l'insieme da codificare ha una cardinalità maggiore di 2^n se ne può dare solo una rappresentazione approssimata o parziale
 - Operazioni di limitazione
 - Operazioni di partizionamento

Numeri interi

- I numeri interi sono un insieme discreto illimitato.
- Per poter essere codificati devono essere limitati.
- Sottoinsieme simmetrico rispetto allo 0.
- Si usa 1 bit per rappresentare il segno e i restanti $a = n-1$ per rappresentare il modulo.
- Il massimo numero rappresentabile è (in modulo) 2^a-1 .
- Se il risultato di un'operazione eccede il modulo 2^a-1 non può essere codificato e il calcolatore restituisce un messaggio di overflow.


Numeri reali

- I numeri reali sono un insieme continuo e illimitato.
- Per poterli rappresentare occorre limitarli (in modo simmetrico rispetto allo 0) e partizionarli.
- *Rappresentazione in virgola fissa*: Degli n bit della parola, 1 rappresenta il segno, a rappresentano le cifre prima della virgola e b le cifre dopo la virgola.
 - Il massimo numero rappresentabile è $(2^{n-1}-1)/2^b$
 - L'accuratezza assoluta è 2^{-b}
- *Rappresentazione in virgola mobile*: (Floating point) espressa nella forma $\rightarrow s0.M B^{seE}$

Rappresentazione delle immagini


- Le immagini sono informazioni continue in tre dimensioni: due spaziali ed una colorimetrica.
- Per codificarle occorre operare tre discretizzazioni.
 - Due discretizzazioni spaziali riducono l'immagine ad una matrice di punti colorati, detti pixel.
 - La terza discretizzazione limita l'insieme di colori che ogni pixel può assumere.

Esempio: Livelli di grigio



- La codifica associa un unico codice ad un intervallo di livelli di grigio
- Tutti i livelli di grigio all'interno dell'intervallo vengono codificati allo stesso modo comportando una perdita di informazione
- Il livello di grigio originale non può essere ricostruito in maniera esatta dal codice binario

Esempio: Dimensione



Un'immagine di 100X100 pixel a 256 colori richiede 10000 byte (10 Kb) per essere rappresentata.

Immagini bitmap



8 bit




5 bit



4 bit



3 bit



1 bit

Immagini vettoriali

- La grafica vettoriale scompone in gruppi logici di componenti (linee, cerchi, rettangoli, ecc.)
- Le forme vengono memorizzate in termini di coordinate e colori dei vari elementi geometrici che le compongono
- Durante la visualizzazione, coordinate e colori vengono utilizzati per ricreare l'immagine
- La grafica vettoriale e' comunemente usata nei disegni, disegni animati e nella grafica lineare in generale

Esempio: Oggetti lineari






Immagine = $x_0, y_0, x_1, y_1, x_2, y_2, x_3, y_3, x_4, y_4, x_5, y_5, x_6, y_6, \text{rosso}$

Esempio: immagini vettoriali



Codifica di un filmato video

$$size = s_{rate} \cdot T \cdot s_{size} = s_{rate} \cdot T \cdot \log_2 n_{col} \cdot n_x \cdot n_y$$



s_{rate} = frame rate

n_{col} = numero di colori

$n_x n_y$ = dimensione del frame

Filmato di 10 minuti a 25 frame al secondo, con risoluzione di 100x100 pixel a 256 colori: dimensione complessiva di $600 \times 25 \times 100 \times 100 \times 8 = 1.2\text{Gbit}$.

Codifica di segnali analogici

- *Segnale*: Quantita' fisica che varia nel tempo
 - *Analogico*: tempo-continuo, valore-continuo
 - *Digitale*: tempo-discreto, valore-discreto
- La codifica digitale di un segnale continuo comporta:
 - *Campionamento* (discretizzazione nel tempo)
 - *Quantizzazione* (discretizzazione nel valore)


$$size = s_{rate} \cdot T \cdot s_{size}$$

frequenza di
campionamento

Durata

Dimensione del campione

Esempi di segnali analogici



a) Velocità del flusso sanguigno nell'arteria cerebrale di un soggetto umano



b) EMG (contrazione e rilassamento della lingua)



c) Angolo di rotazione del ginocchio




d) ECG




e) Frequenza cardiaca istantanea in battiti al minuto (100 battiti)

Campionamento e quantizzazione



File finale = 001-010-101-110-110-010-001-010-011-110-111-010-001-100-011-110-101-010-001


Campionamento e quantizzazione



File finale = 001-010-101-110-110-010-001-010-011-110-111-010-001-100-011-110-101-010-001


Codifica del suono

- Il suono è un segnale analogico tempo-continuo
- Un'onda sonora non è altro che una successione di rarefazioni e compressioni di piccole porzioni d'aria



Una descrizione del suono

- Il suono prodotto da un altoparlante e' prodotto dalla vibrazione di una membrana.
- Descrivendo la posizione della membrana nel tempo (e quindi il suo spostamento) a tutti gli effetti descriviamo il suono.



Il suono percepibile dall'orecchio umano viene riprodotto fedelmente se la frequenza di campionamento (il numero di campioni in un secondo) è non inferiore a 30KHz.

Lo standard telefonico prevede un campionamento a 8KHz ed una quantizzazione a 256 livelli (codificati con 8 bit). Quindi per ogni secondo di conversazione servono 64Kbit

Questo tipo di codifica e' comunemente utilizzato nel formato WAVE

Formato MIDI

(Musical Instrument Digital Interface)

- Il formato MIDI ha, tra i formati audio, lo stesso ruolo che, tra i formati grafici, ha il formato vettoriale.
- Un file MIDI non è una registrazione sonora
- Contiene comandi che, quando eseguiti, producono dei suoni (mediante un sintetizzatore hardware o software).
- I file MIDI, per questo motivo, sono molto piccoli rispetto ai file audio, ma riproducono un suono "sintetico", non registrato.
- Un file MIDI ha una forma del tipo:
 - Suona la nota x per un tempo t con lo strumento y

Compressione dei dati

- Tecniche di compressione vengono utilizzate ogni qualvolta si deve ridurre la dimensione dei dati su cui si sta lavorando
- Archiviazione (i supporti di memorizzazione sono limitati)
- Trasmissione (la velocità di comunicazione sulla rete o verso certe periferiche può rappresentare un fattore importante)

La ridondanza dei dati

- Una codifica e' detta ridondante se utilizza piu' bit del necessario. Es: Codice ASCII a 8 bit
- Se la codifica e' ridondante il valore di alcuni bit diventa prevedibile conoscendo gli altri
- Si dice che il contenuto informativo e' inferiore al 2^n per una codifica ridondante a n bit
- In altri termini, alcuni bit non aggiungono informazione a quanto gia' codificato dai precedenti

L'utilità della ridondanza

- L'uso di codifiche ridondanti può avere due motivazioni: la *flessibilità* e l'*affidabilità*.
- *La flessibilità*: possibilità di utilizzare la stessa codifica in situazioni diverse. Es: "Millennium Bug"
- *L'affidabilità*: facilmente comprensibile e non incline ad essere male interpretato anche nel caso in cui il messaggio venga trasmesso in modo solo parziale o corrotto.

Esempio di ridondanza

- Nella lingua italiana l'utilizzo della lettera “*q*” e' un chiaro esempio di ridondanza
- La lettera “*q*” e' sempre seguita dalla lettera “*u*”
- La parola “*quadro*” sarebbe comprensibile anche se scritta “*q*adro*” benché non corretta
- In generale: *tutto ciò che si riesce ad indovinare e' ridondante nel contesto in cui viene utilizzato*

Compressione e ridondanza

- Un primo esempio di compressione della lingua italiana e' quello di omettere il carattere "u" tutte le volte che questo e' preceduto dal carattere "q"
- Qualcosa del genere viene comunemente fatto quando si scrive "xche'" al posto di "perche'" o "ke" al posto di "che".
- In generale, tutte le codifiche ridondanti si prestano ad essere compresse

Tecniche generiche di compressione

- *Lossless*: tecnica senza perdita di informazione
 - *permettono di recuperare interamente l'informazione contenuta nel testo prima della sua compressione*
 - *Utilizzate nei casi in cui non e' possibile accettare neppure la minima perdita delle informazioni Es: Winzip*
- *Lossy*: tecnica distruttiva con perdita di informazione
 - *Non e' possibile ricostruire in maniera esatta i dati di partenza attraverso il processo di decompressione.*
 - *Utilizzate nella compressione delle immagini, dei filmati e dei suoni → riduzione della qualità*

Compressione Run Length Encoding (RLE)

- Algoritmo di compressione di tipo lossless
- Si basa sul fatto che nei dati da comprimere esistono sequenze, dette *run*, che si ripetono costantemente
- Una volta individuate le sequenze ripetute, vengono sostituite da un unico simbolo e dal numero delle ripetizioni presenti.

Esempio di compressione (*RLE*)

- una stringa di bit del tipo “ 011100001 ” verrebbe compressa codificandola in “03*14*01” che si legge “ 0, *tre volte* 1, *quattro volte* 0, 1 ” .
- Varianti di RLE si basano sulla diversa lunghezza minima da attribuire ad un *run*.
- Nell' esempio abbiamo usato *run* pari a uno
- Possiamo prendere in considerazione gruppi di simboli ($run > 1$) e trovare quante volte l'intero gruppo viene ripetuto all' interno della stringa.

Compressione a codifica differenziale

- Spesso le informazioni sono costituite da blocchi di dati, ognuno dei quali differisce leggermente dal precedente
 - Es: fotogrammi successivi di un filmato
- In questo caso la compressione differenziale memorizza non il blocco stesso ma le sue differenze rispetto al precedente

Compressione adattativa basata su dizionario

- Il termine dizionario si riferisce all' insieme di elementi di base sui quali viene ricostruito il messaggio compresso.
- I simboli del dizionario rappresentano particolari sequenze di bit e durante la compressione, ad ogni sequenza riconosciuta viene sostituito il simbolo corrispondente.
- Il dizionario viene creato dinamicamente durante il processo di compressione.
- L' algoritmo di compressione *Lempel-Ziv* si basa su questa tecnica (WinZip)

Compressione delle immagini

- Nella compressione delle immagini si usano sia tecniche di tipo *lossy* che tecniche di tipo *lossless*
- GIF, PNG → *lossless*
- JPEG → *lossy*
- La compressione di tipo *lossy* dà ottimi risultati per quanto riguarda la dimensione del file prodotto apportando, in alcuni casi, perdite non visibili.
- La compressione di tipo *lossless* dà buoni risultati per immagini a colori piatti (poco efficiente su immagini molto complesse e sfumate)

Formato GIF

(*Graphic Interchange Format*)

- Max 256 colori → profondità di colore 8 bit.
- Se l'immagine originale contiene un numero più elevato di colori è necessario effettuare una riduzione con conseguente perdita di qualità
- Integra una compressione di tipo LZW (ZIP)
- I colori sono memorizzati in una 'tavolozza', una tabella che associa un numero ad un certo valore di colore.
- Supporta il formato *interlacciato*
- consente anche di definire un colore come *trasparente*.

Formato JPEG/JPG

(Joint Photographic Expert Group)

- 24 bit = 16,8 milioni di colori.
- Tecnica di compressione basata di una codifica dell'immagine *perceptiva* in cui viene distinta la luminosità dei pixel dal loro colore.
- Per ogni pixel viene codificata la componente della luminosità mentre il colore viene codificato a blocchi di 4 pixel; (codificando il colore medio dei quattro)
- Per 4 pixel → 6 valori (4 di luminosità e 2 di colore) anziché 12 valori come in 24 bit (RGB)
- E' possibile scegliere il grado di compressione/qualità'
- Il formato JPEG progressivo emula l'interlacciamento

Formato PNG

(Portable Network Graphic)

- 8, 16, 24 bit = 256, 65536, 16.8 milioni di colori.
- Non è in grado di raggiungere l'efficienza del formato JPEG per quanto riguarda il fattore di compressione
- Supporta sia l'effetto trasparenza che l'interlacciamento
- Può incorporare del testo all'interno dell'immagine (come stringa) utile per classificarla e per fare ricerche sui contenuti